

✓ Análisis de Calidad de Vinos Tintos y Blancos

✓ Descarga de Datos

```
1 import requests
2 import os
3 import pandas as pd
4 import numpy as np
5 import matplotlib.pyplot as plt
6 import seaborn as sns
```

```
1
2 url_red = 'http://archive.ics.uci.edu/ml/machine-learning-databases/wine-quality/winequality-red.csv'
3 url_white = 'http://archive.ics.uci.edu/ml/machine-learning-databases/wine-quality/winequality-white.csv'
4
5 os.makedirs('../data/raw', exist_ok=True)
6 os.makedirs('../data/processed', exist_ok=True)
7
8 with open('../data/raw/winequality-red.csv', 'wb') as red:
9     red.write(requests.get(url_red).content)
10 with open('../data/raw/winequality-white.csv', 'wb') as white:
11     white.write(requests.get(url_white).content)
```

✓ Combinar los Datos

```
1
2 red_df = pd.read_csv('../data/raw/winequality-red.csv', sep=';')
3 white_df = pd.read_csv('../data/raw/winequality-white.csv', sep=';')
4
5 red_df['type'] = 'red'
6 white_df['type'] = 'white'
7
8 wines_df = pd.concat([red_df, white_df], ignore_index=True)
9 wines_df.to_csv('../data/processed/wines.csv', index=False)
```

✓ Conteo de Registros y Variables

```
1 print(wines_df.info())
2 print(wines_df.shape)

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 6497 entries, 0 to 6496
Data columns (total 13 columns):
 #   Column           Non-Null Count  Dtype  
--- 
 0   fixed acidity    6497 non-null   float64
 1   volatile acidity 6497 non-null   float64
 2   citric acid      6497 non-null   float64
 3   residual sugar   6497 non-null   float64
 4   chlorides        6497 non-null   float64
 5   free sulfur dioxide 6497 non-null   float64
 6   total sulfur dioxide 6497 non-null   float64
 7   density          6497 non-null   float64
 8   pH               6497 non-null   float64
 9   sulphates        6497 non-null   float64
 10  alcohol          6497 non-null   float64
 11  quality          6497 non-null   int64  
 12  type              6497 non-null   object 
dtypes: float64(11), int64(1), object(1)
memory usage: 660.0+ KB
None
(6497, 13)
```

```

1 var_type = wines_df.dtypes.value_counts()
2 print(f'Observamos que tenemos {wines_df.shape[0]} registros, con {wines_df.isnull().sum().sum()} valores nulos')
3 print(f'El tipo de variables es: \n\n{var_type}')
4

```

Observamos que tenemos 6497 registros, con 0 valores nulos y 13 variables
El tipo de variables es:

```

float64    11
int64      1
object     1
Name: count, dtype: int64

```

▼ Filtrar Atípicos y Manejar Datos Ausentes

A continuación, realizaremos un estudio de los datos con el objetivo de obtener conclusiones sobre las variables que influyen en la obtención de un vino de alta calidad, en contraposición a aquellas que resultan en vinos de calidad inferior.

```
1 wines_df.describe()
```

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH
count	6497.000000	6497.000000	6497.000000	6497.000000	6497.000000	6497.000000	6497.000000	6497.000000	6497.000000
mean	7.215307	0.339666	0.318633	5.443235	0.056034	30.525319	115.744574	0.994697	3.218501
std	1.296434	0.164636	0.145318	4.757804	0.035034	17.749400	56.521855	0.002999	0.160787
min	3.800000	0.080000	0.000000	0.600000	0.009000	1.000000	6.000000	0.987110	2.720000
25%	6.400000	0.230000	0.250000	1.800000	0.038000	17.000000	77.000000	0.992340	3.110000
50%	7.000000	0.290000	0.310000	3.000000	0.047000	29.000000	118.000000	0.994890	3.210000
75%	7.700000	0.400000	0.390000	8.100000	0.065000	41.000000	156.000000	0.996990	3.320000
max	15.900000	1.580000	1.660000	65.800000	0.611000	289.000000	440.000000	1.038980	4.010000

▼ Filtrar Datos Ausentes

```

1 # Crear una copia para filtrar valores atípicos y nulos
2 df_wines_copy = wines_df.copy()
3 df_wines_copy.columns = df_wines_copy.columns.str.replace(' ', '_')
4 df_wines_copy.describe()

```

	fixed_acidity	volatile_acidity	citric_acid	residual_sugar	chlorides	free_sulfur_dioxide	total_sulfur_dioxide
count	6497.000000	6497.000000	6497.000000	6497.000000	6497.000000	6497.000000	6497.000000
mean	7.215307	0.339666	0.318633	5.443235	0.056034	30.525319	115.744577
std	1.296434	0.164636	0.145318	4.757804	0.035034	17.749400	56.521857
min	3.800000	0.080000	0.000000	0.600000	0.009000	1.000000	6.000000
25%	6.400000	0.230000	0.250000	1.800000	0.038000	17.000000	77.000000
50%	7.000000	0.290000	0.310000	3.000000	0.047000	29.000000	118.000000
75%	7.700000	0.400000	0.390000	8.100000	0.065000	41.000000	156.000000
max	15.900000	1.580000	1.660000	65.800000	0.611000	289.000000	440.000000

```
1 df_wines_copy['type'].value_counts()
```

```
count  
type  
white    4898  
red      1599  
  
dtype: int64
```

```
1 print(df_wines_copy.isnull().sum())  
  
fixed_acidity      0  
volatile_acidity   0  
citric_acid        0  
residual_sugar     0  
chlorides          0  
free_sulfur_dioxide 0  
total_sulfur_dioxide 0  
density            0  
pH                 0  
sulphates          0  
alcohol            0  
quality            0  
type               0  
dtype: int64
```

```
1 # df_wines_copy.dropna(inplace=True)
```

▼ Filtrar Valores Atípicos

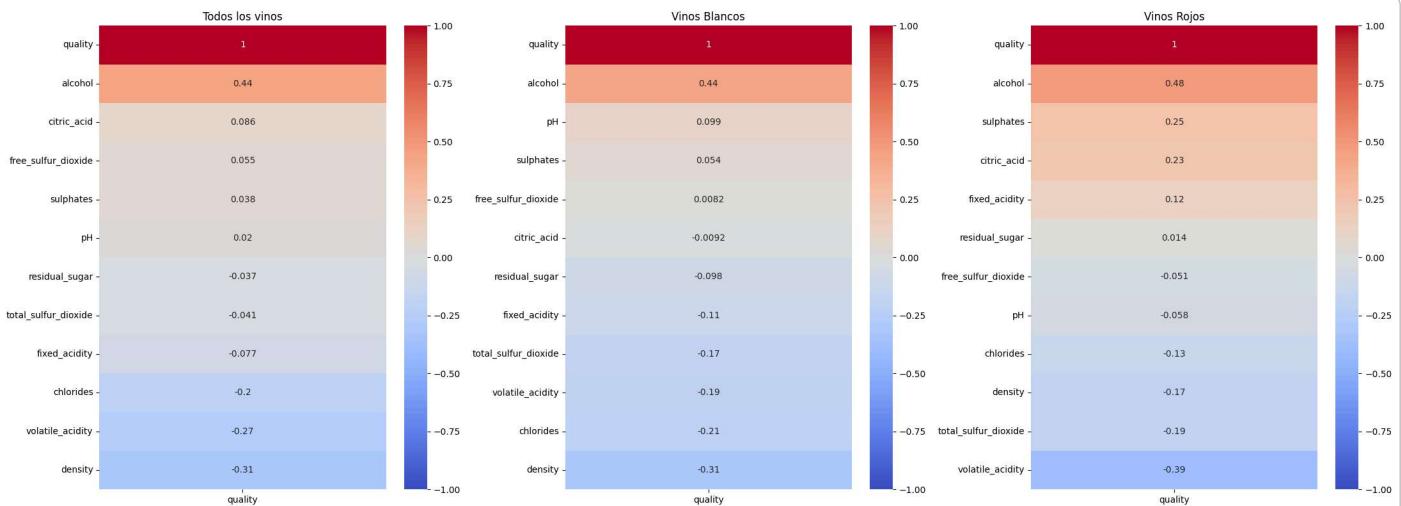
```
1 # Lista de columnas numéricas a analizar (en este caso todas las que aparecen en describe)  
2 columnas_numericas = df_wines_copy.select_dtypes(include=['float64', 'int64']).columns
```

```
1 # Calcular la matriz de correlación para todos los tipos de vinos  
2 corr_matrix = df_wines_copy[columnas_numericas].corr()
```

```
1 # Calcular la matriz de correlación para todos los vinos blancos  
2  
3 corr_matrix_white = df_wines_copy[df_wines_copy['type'] == 'white'][columnas_numericas].corr()
```

```
1 # Calcular la matriz de correlación para todos los vinos tintos  
2  
3 corr_matrix_red = df_wines_copy[df_wines_copy['type'] == 'red'][columnas_numericas].corr()
```

```
1 # Visualizar la correlación entre cada variable y la calidad del vino entre todos los vinos, rojos y blancos  
2  
3 fig, axes = plt.subplots(1, 3, figsize=(22, 8))  
4  
5 sns.heatmap(corr_matrix[['quality']].sort_values(by='quality', ascending=False),  
6               annot=True, cmap='coolwarm', vmin=-1, vmax=1, ax=axes[0])  
7 axes[0].set_title('Todos los vinos')  
8  
9 sns.heatmap(corr_matrix_white[['quality']].sort_values(by='quality', ascending=False),  
10              annot=True, cmap='coolwarm', vmin=-1, vmax=1, ax=axes[1])  
11 axes[1].set_title('Vinos Blancos')  
12  
13 sns.heatmap(corr_matrix_red[['quality']].sort_values(by='quality', ascending=False),  
14              annot=True, cmap='coolwarm', vmin=-1, vmax=1, ax=axes[2])  
15 axes[2].set_title('Vinos Rojos')  
16  
17 plt.tight_layout()  
18 plt.show()
```



Definir un umbral para las correlaciones negativas e Identificacion de las variables que afectan negativamente a la calidad del vino por separado.

```
1 # Definir un umbral para las correlaciones negativas
2 correlation_threshold = -0.1 # Por ejemplo, -0.1
```

```
1 # Identificar las variables que afectan negativamente a la calidad del vino tinto
2 negative_corr_vars_red = corr_matrix_red['quality'][corr_matrix_red['quality'] < correlation_threshold].index
3 print("Variables que afectan negativamente a la calidad del vino tinto:", negative_corr_vars_red)
4
5 # Identificar las variables que afectan negativamente a la calidad del vino blanco
6 negative_corr_vars_white = corr_matrix_white['quality'][corr_matrix_white['quality'] < correlation_threshold]
7 print("Variables que afectan negativamente a la calidad del vino blanco:", negative_corr_vars_white)
```

Variables que afectan negativamente a la calidad del vino tinto: ['volatile_acidity', 'chlorides', 'total_sulfur_dioxide']
 Variables que afectan negativamente a la calidad del vino blanco: ['fixed_acidity', 'volatile_acidity', 'chlorides', 'total_sulfur_dioxide']

Funicon para filtrar los atipicos solo de las variables identificadas.

```
1 def remove_negative_outliers_iqr(df, negative_vars):
2     df_filtered = df.copy()
3     for column in negative_vars:
4         Q1 = df[column].quantile(0.25)
5         Q3 = df[column].quantile(0.75)
6         IQR = Q3 - Q1
7         lower_bound = Q1 - 1.5 * IQR
8         upper_bound = Q3 + 1.5 * IQR
9         df_filtered = df_filtered[(df_filtered[column] >= lower_bound) & (df_filtered[column] <= upper_bound)]
10    return df_filtered
```

```
1 # Separar los DataFrames por tipo de vino
2 df_red = df_wines_copy[df_wines_copy['type'] == 'red'].copy()
3 df_white = df_wines_copy[df_wines_copy['type'] == 'white'].copy()
4
5 # Aplicar la función de filtrado a los DataFrames de vinos tintos y blancos
6 df_red_filtered = remove_negative_outliers_iqr(df_red, negative_corr_vars_red)
7 df_white_filtered = remove_negative_outliers_iqr(df_white, negative_corr_vars_white)
```

```
1 # Realizamos un concatenado de los dos dataframes filtrados
2
3 df_wines_filtered = pd.concat([df_red_filtered, df_white_filtered], ignore_index=True)
```

```

1 print("Descripción del DataFrame original:")
2 display(df_wines_copy.describe())
3
4 print("\nDescripción del DataFrame filtrado:")
5 display(df_wines_filtered.describe())

```

Descripción del DataFrame original:

	fixed_acidity	volatile_acidity	citric_acid	residual_sugar	chlorides	free_sulfur_dioxide	total_sulfur_dioxide
count	6497.000000	6497.000000	6497.000000	6497.000000	6497.000000	6497.000000	6497.000000
mean	7.215307	0.339666	0.318633	5.443235	0.056034	30.525319	115.74457
std	1.296434	0.164636	0.145318	4.757804	0.035034	17.749400	56.52185
min	3.800000	0.080000	0.000000	0.600000	0.009000	1.000000	6.000000
25%	6.400000	0.230000	0.250000	1.800000	0.038000	17.000000	77.000000
50%	7.000000	0.290000	0.310000	3.000000	0.047000	29.000000	118.000000
75%	7.700000	0.400000	0.390000	8.100000	0.065000	41.000000	156.000000
max	15.900000	1.580000	1.660000	65.800000	0.611000	289.000000	440.000000

Descripción del DataFrame filtrado:

	fixed_acidity	volatile_acidity	citric_acid	residual_sugar	chlorides	free_sulfur_dioxide	total_sulfur_dioxide
count	5794.000000	5794.000000	5794.000000	5794.000000	5794.000000	5794.000000	5794.000000
mean	7.163971	0.325676	0.315906	5.482560	0.051123	30.687004	115.03702
std	1.218262	0.151971	0.137875	4.692735	0.019153	17.252842	55.70251
min	4.600000	0.080000	0.000000	0.600000	0.015000	1.000000	6.000000
25%	6.400000	0.220000	0.250000	1.800000	0.038000	17.000000	77.000000
50%	7.000000	0.280000	0.310000	3.000000	0.046000	29.000000	117.000000
75%	7.600000	0.380000	0.390000	8.200000	0.060000	42.000000	155.000000
max	15.900000	1.005000	1.660000	23.500000	0.119000	128.000000	255.000000

```

1 # Comparación de histogramas entre el DataFrame original y el filtrado
2
3 for col in columnas_numericas:
4     plt.figure(figsize=(12, 5))
5
6     plt.subplot(1, 2, 1)
7     plt.hist(df_wines_copy[col], bins=30, edgecolor='black')
8     plt.title(f'Histograma Original Vinos - {col}')
9     plt.xlabel(col)
10    plt.ylabel('Frecuencia')
11
12    plt.subplot(1, 2, 2)
13    plt.hist(df_wines_filtered[col], bins=30, edgecolor='black')
14    plt.title(f'Histograma Vinos Filtrados - {col}')
15    plt.xlabel(col)
16    plt.ylabel('Frecuencia')
17
18    plt.tight_layout()
19    plt.show()
20

```